

Predicción de Deserción Estudiantil con LightGBM y Explicabilidad en Lenguaje Natural

Clasificación binaria con SHAP y LLM (Groq) para orientación académica

Helen Valentina Sanabria Guevara

hvsanabrig@eafit.edu.co

Jerónimo Rodríguez Restrepo

jrodrigur3@eafit.edu.co

Juan Esteban Orrego Gomez

jeorregog1@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: <https://github.com/Valesague52/Proyecto-Final---IA->

Resumen

Contexto: La deserción estudiantil universitaria representa una pérdida significativa para estudiantes e instituciones. Detectar tempranamente a los estudiantes en riesgo permite activar intervenciones oportunas de bienestar. **Objetivo:** Construir un sistema que prediga el riesgo de deserción y genere explicaciones en lenguaje natural dirigidas a consejeros universitarios. **Método:** Se entrenó un clasificador LightGBM con tuning de hiperparámetros sobre el dataset *Student Dropout Prediction* (Kaggle/UCI, $N = 4424$, 35 variables). Las predicciones se complementan con valores SHAP y un LLM (llama-3.1-8b-instant vía Groq) que genera explicaciones personalizadas en español mediante few-shot prompting. **Resultados:** El modelo alcanzó $F1 = 0.804$ y $AUC-ROC = 0.929$ en el conjunto de prueba, superando el baseline logístico balanceado. El componente LLM obtuvo un score de calidad promedio de 91.7 % en evaluación LLM-as-a-judge (3 criterios, $n = 8$ casos). **Conclusión:** La combinación de LightGBM con SHAP y LLM produce un sistema interpretable y accionable. Como extensión se propone integrar RAG sobre reglamentos institucionales y desplegar una interfaz para consejeros.

Palabras clave: LightGBM, SHAP, LLM, Deserción Estudiantil, Clasificación Binaria, Explicabilidad, Groq.

1. Introducción

La deserción estudiantil es uno de los principales desafíos de la educación superior en América Latina. En Colombia, tasas de abandono superiores al 40 % representan pérdidas humanas, sociales y económicas considerables [6]. La detección temprana de estudiantes en riesgo permite a las instituciones activar intervenciones de bien-

estar antes de que el abandono sea definitivo.

Este proyecto aborda la siguiente pregunta de investigación:

“¿Puede un clasificador LightGBM con tuning de hiperparámetros predecir el riesgo de deserción estudiantil con un F1 superior al de una regresión logística balanceada, y pueden sus predicciones complementarse con explicaciones en lenguaje natural generadas por un LLM?”

Se utilizó el dataset *Predict Students' Dropout and Academic Success* [2], con 4 424 registros de estudiantes portugueses y 35 variables académicas, demográficas y financieras. La variable objetivo es binaria: deserción vs. graduación o matrícula activa.

El sistema resultante combina tres capas: (i) un clasificador LightGBM para la predicción, (ii) SHAP para explicaciones locales del modelo, y (iii) un LLM que traduce los factores SHAP a lenguaje natural accionable para consejeros universitarios.

El documento se organiza así: la Sección 2 describe los datos y el EDA; la Sección 3 presenta la arquitectura del sistema; la Sección 4 detalla la metodología experimental; la Sección 5 reporta los resultados; la Sección 6 discute los hallazgos; y la Sección 7 concluye.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	Kaggle / UCI [2]
Registros	4 424 estudiantes
Features	35 (numéricas y categóricas)
Objetivo	Binaria: deserción (1) vs. no (0)
Versión	2022
Tamaño	≈1.2 MB

La variable objetivo original tiene tres clases (*Dropout*, *Graduate*, *Enrolled*). Se binarizó conservando *Dropout* como clase positiva (1) y unificando *Graduate* y *Enrolled* como clase negativa (0), resultando en un desbalance de aproximadamente 32 % positivos vs. 68 % negativos.

2.2. Hallazgos del análisis exploratorio

Figura 1 — Variable Objetivo: Distribución y Proporciones




Figura 1: Distribución de la variable objetivo. La clase positiva (Deserción) representa el 32 % del dataset.

El análisis exploratorio reveló cuatro hallazgos principales:

- **Desbalance moderado:** ≈32 % de estudiantes desertores, lo que motivó el uso de `class_weight = 'balanced'` en todos los modelos y stratified split.
- **Variables financieras críticas:** los estudiantes con deudas o sin becas presentan tasas de deserción significativamente mayores, como se observa en la Figura 1.
- **Rendimiento del primer semestre:** los estudiantes que abandonan muestran promedios de materias aprobadas notablemente inferiores desde el primer semestre, patrón visible en las distribuciones de desempeño académico.
- **Sin valores nulos:** el dataset no requirió imputación. Los valores extremos detectados (e.g., cero materias aprobadas) son académicamente válidos y se conservaron, dado que LightGBM es robusto a outliers por su naturaleza basada en árboles.

Figura 4 — Mapa de Correlaciones (Variables Numéricas)



Figura 2: Mapa de correlaciones. Las variables académicas del segundo semestre presentan la correlación más alta con la deserción.

3. Arquitectura del Sistema

La arquitectura se diseñó como un flujo modular de tres capas orientado a la predicción del riesgo de deserción y a la generación de explicaciones accionables para consejeros universitarios.




Figura 3: Arquitectura general del sistema de predicción y explicabilidad.

3.1. Componentes principales

Preprocesamiento. La primera capa recibe el dataset crudo y aplica binarización de la variable objetivo, escalado `StandardScaler` ajustado *solo* en entrenamiento para evitar data leakage, y división estratificada 70 %/15 %/15 % con `random_state=42`. No se requirió imputación (dataset sin nulos).

Motor predictivo (LightGBM). La segunda capa implementa el baseline lineal de referencia (`logreg_balanced`) y el modelo principal LightGBM. Este último fue seleccionado por su buen desempeño en datos tabulares, su capacidad para capturar relaciones no lineales y su eficiencia para explorar interacciones complejas entre variables académicas, financieras y demográficas.

Explicabilidad con SHAP. Para cada predicción, `shap.TreeExplainer` calcula las contribuciones individuales de cada variable a la predicción del modelo. Los valores SHAP permiten identificar los factores que más empujan al estudiante hacia el riesgo o hacia la seguridad.

Componente LLM. El módulo de IA generativa utiliza `llama-3.1-8b-instant` vía la API gratuita de Groq [5]. Recibe los tres factores SHAP más relevantes de cada estudiante y genera una explicación personalizada en español mediante `few-shot prompting`, con recomendaciones concretas dirigidas a consejeros universitarios.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros del modelo LightGBM final

Parámetro	Valor
<code>n_estimators</code>	300
<code>learning_rate</code>	0.1
<code>max_depth</code>	5
<code>num_leaves</code>	127
<code>min_child_samples</code>	10
<code>subsample</code>	0.9
<code>colsample_bytree</code>	0.7
<code>reg_alpha</code>	0.0
<code>reg_lambda</code>	0.5
<code>class_weight</code>	'balanced'
Framework	scikit-learn / LightGBM 4.6
Hardware	CPU (local)

4.2. Estrategia de validación

Se adoptó un esquema `hold-out` con tres conjuntos fijos (70 %/15 %/15 %, estratificados por clase). El conjunto de prueba permaneció completamente aislado durante todas las fases de entrenamiento y `tuning` para garantizar una evaluación final imparcial. Durante el `tuning` de hiperparámetros se utilizó `PredefinedSplit` para que `RandomizedSearchCV` respetara la separación entre `train` y `val` sin cruzar información.

La métrica principal de selección fue F1, que balancear precisión y `recall` es fundamental en problemas con desbalance de clases. Desde la perspectiva aplicada, el `recall` adquiere especial relevancia al buscar identificar correctamente a los estudiantes en riesgo: un falso negativo (estudiante en riesgo no detectado) tiene consecuencias más graves que una falsa alarma.

4.3. Experimentos realizados

1. **Baseline mínimo:** `DummyClassifier(strategy='prior')`, establece el piso del problema.

2. **Baseline competitivo:** `LogisticRegression` balanceada (`logreg_balanced`), referencia lineal sólida.
3. **LightGBM base:** modelo con hiperparámetros por defecto y `class_weight='balanced'`.
4. **LightGBM tuneado:** búsqueda aleatoria de hiperparámetros (`RandomizedSearchCV`, 30 iteraciones) sobre el espacio definido en la Tabla 2.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de candidatos – conjunto de validación

Modelo	Acc.	F1	AUC
Dummy (prior)	0.678	0.000	0.500
LightGBM base	0.861	0.779	0.922
LogReg balanceada	0.871	0.805	0.926
LightGBM tuned	0.877	0.806	0.924

Cuadro 4: Modelo final – conjunto de prueba (primera evaluación)

Modelo	Acc.	F1	AUC
LightGBM tuned	0.874	0.804	0.929

La Tabla 3 muestra que el modelo tuneado supera al baseline logístico en F1 (+0,0003). Aunque la mejora es marginal, se sostiene en prueba (Tabla 4), confirmando generalización robusta ($\Delta F1_{val \rightarrow test} = -0,002$).




Figura 4: Comparación de candidatos en validación por métrica.

5.2. Análisis de errores




Figura 5: Matriz de confusión en prueba. TP = 172, TN = 481, FP = 43, FN = 41.




Figura 6: Curva ROC del modelo final (AUC = 0.929).

El modelo detectó correctamente el 80.7 % de los estudiantes en riesgo real (TP = 172 de 213), con 41 falsos negativos cuya probabilidad promedio fue ≈ 0.39 — casos genuinamente ambiguos en la frontera de decisión, no errores sistemáticos.

5.3. Importancia de variables




Figura 7: Top 15 variables por importancia SHAP.

Las variables más influyentes son el rendimiento académico del segundo semestre (materias aprobadas y notas), el estado de pago de matrícula, y la edad al momento de la matrícula, hallazgo consistente con la literatura [1].

5.4. Componente LLM

La evaluación cuantitativa LLM-as-a-judge sobre 8 casos con 3 criterios binarios (menciona factores correctos, tono adecuado, da recomendación) arrojó un score promedio de 91.7 %. El Listing 1 muestra un ejemplo representativo para un estudiante con riesgo alto.

1. Bajo rendimiento: aprobo muy pocas materias en 2do semestre. Recomendación: plan de acompañamiento académico urgente.
2. Situación financiera: no esta al día con matrícula. Recomendación: orientar a oficina de becas.
3. Factores acumulados: combinación amplifica el riesgo. Recomendación: cita con bienestar universitario.

Listing 1: Output del sistema LLM para estudiante con $P(\text{deserción}) = 0.84$.

6. Discusión

6.1. Interpretación de resultados

El sistema logró el objetivo planteado. El clasificador LightGBM tuneado supera al baseline logístico en F1 y generaliza bien al conjunto de prueba ($\Delta F1 = -0.002$, $\Delta AUC = +0.005$). El AUC en prueba (0.929) supera levemente al de validación (0.924), lo que sugiere que el conjunto de validación era ligeramente más exigente — no un indicio de data leakage, ya que los splits fueron generados con estratificación y `random_state=42` previos a cualquier entrenamiento.

El componente LLM cumple su rol complementario: no reemplaza al modelo predictivo, sino que hace accesibles

los factores SHAP a consejeros sin formación en ML. El score de calidad de 91.7 % confirma que las explicaciones son coherentes, empáticas y contienen recomendaciones concretas en casi todos los casos evaluados.

6.2. Limitaciones

- **Contexto geográfico:** el dataset proviene de una institución portuguesa; los patrones de deserción pueden diferir en el contexto colombiano o latinoamericano.
- **Variables temporales ausentes:** no se dispone de información longitudinal (evolución semestre a semestre), lo que limitaría la detección temprana en semestres iniciales.
- **Escala del LLM:** se utilizó un modelo de 8B parámetros por disponibilidad gratuita; modelos más grandes podrían generar explicaciones más matizadas.
- **Evaluación del LLM:** el LLM-as-a-judge no reemplaza la validación con expertos en orientación académica.

6.3. Trabajo futuro

1. **RAG institucional:** integrar un módulo de recuperación sobre reglamentos y políticas de bienestar universitario para enriquecer las recomendaciones del LLM con referencias concretas.
2. **Interfaz Streamlit:** desplegar el sistema como aplicación web que permita a los consejeros ingresar perfiles y obtener predicciones y explicaciones en tiempo real, sin necesidad de ejecutar notebooks.

7. Conclusiones

Este trabajo demostró que es posible construir un sistema interpretable de predicción de deserción estudiantil combinando tres capas complementarias: clasificación con LightGBM, explicaciones locales con SHAP, y generación de lenguaje natural con un LLM gratuito (Groq).

En respuesta a la pregunta de investigación: el clasificador LightGBM tuneado **sí supera al baseline** logístico balanceado, alcanzando $F1 = 0.804$ y $AUC = 0.929$ en el conjunto de prueba. La mejora en F1 es marginal (+0,0003 en validación), pero la ventaja real del modelo es su capacidad para capturar relaciones no lineales y su integración natural con SHAP para explicabilidad local.

Los tres hallazgos clave son: (i) el rendimiento académico del segundo semestre es el predictor más potente, consistente con la literatura sobre integración académica [1]; (ii) las variables financieras (estado de pago, becas) tienen un peso relevante, lo que refuerza la necesidad de intervenciones socioeconómicas tempranas; y (iii) el componente LLM demostró que la explicabilidad técnica puede democratizarse: consejeros sin formación en ML

pueden interpretar y actuar sobre las predicciones gracias a las explicaciones generadas.

Contribuciones del equipo

Integrante	Contribución principal
Helen Sanabria	EDA, visualizaciones, secciones 2 y 6.2
Valeria Sague	Preprocesamiento, pipeline, notebook 02
Jorge E. Orrego	Baseline, LightGBM, tuning, secciones 3 y 4
Jerónimo Rodríguez	LLM/SHAP/Groq, evaluación test, repo, secciones 1/5/6.1/7

Distribución de responsabilidades.

Repositorio y Demo

- **GitHub:** <https://github.com/Valesague52/Proyecto-Final---IA->
- **Video demo (≤3 min):** www.youtube.com/watch?v=aOkuu5GL9f8
- **Instalación:** `pip install -r requirements.txt`
- **Notebook principal:** `notebooks/04_llm_rag_agents.ipynb`

Referencias

[1] Tinto, V. (1987). *Leaving College: Rethinking the Causes and Cures of Student Attrition*. University of Chicago Press.

[2] Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2022). *Predict Students' Dropout and Academic Success*. UCI Machine Learning Repository / Kaggle. <https://www.kaggle.com/datasets/thedevastator/higher-education-predictors-of-student-retention>

[3] Ke, G., Meng, Q., Finley, T., et al. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. NeurIPS 2017. <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>

[4] Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017. <https://arxiv.org/abs/1705.07874>

[5] Groq, Inc. (2024). *Groq API Documentation*. <https://console.groq.com/docs>

- [6] Ministerio de Educación Nacional de Colombia. (2022). *Estadísticas de Deserción y Graduación – SPADIES 3.0*. <https://spadies3.mineducacion.gov.co>

A. Hiperparámetros y búsqueda aleatoria

La búsqueda de hiperparámetros se realizó con `RandomizedSearchCV` (30 iteraciones, `PredefinedSplit`) sobre el espacio: `n_estimators` $\in \{100, 200, 300, 500\}$, `learning_rate` $\in \{0,01, 0,05, 0,1, 0,2\}$, `max_depth` $\in \{3, 5, 7, -1\}$, `num_leaves` $\in \{31, 63, 127\}$, `subsample` $\in [0,6,1,0]$, `colsample_bytree` $\in [0,6,1,0]$. Los resultados completos se encuentran en `models/lightgbm_tuning_results.csv`.

B. Diseño del prompt LLM

El sistema utiliza few-shot prompting con dos ejemplos anclados (un caso de alto riesgo y uno de bajo riesgo) para estabilizar el formato y el tono de las respuestas. La temperatura se fijó en 0.4 para balance entre reproducibilidad y naturalidad. El prompt completo y su justificación se documentan en `notebooks/04_llm_rag_agents.ipynb`, celda 4.